

Codificadores visuales en Diffusion Policy

Entrenar la ResNet-18 desde cero supera al preentrenamiento de ImageNet en Push-T

Moises Britez

Máster en Análisis de Datos en Ingeniería · Tecnun · Director: Diego Borro

Donostia-San Sebastián · septiembre de 2026

§ 1

El problema

El codificador visual decide qué llega al generador

- Imitación: la acción se aprende de demostraciones humanas.
- Misma imagen, rutas distintas: la regresión las promedia y descarrila.

Florence *et al.* (2021); Chi *et al.* (2025).

Y todo pasa antes por un cuello de botella: el **codificador visual**.

Diffusion Policy resolvió el generador; el codificador sigue sin decidirse

- Difusión condicionada: acciones multimodales sin promediar.
- Después se cambió el generador y la entrada.
- En Push-T, nadie contrasta ResNet-18, DINOv2 y CLIP bajo el mismo protocolo.

Pregunta: con 206 demostraciones, ¿preentrenar? ¿Congelar o ajustar?

La respuesta corta: el preentrenamiento de ImageNet estorba aquí

1. **Diseño.** Cinco codificadores en la misma política; lo demás, idéntico.
2. **Resultado.** Desde cero 0,864; congelado 0,668; ajustado 0,648.
3. **Coste.** La línea base, además, 3,5 y 9,8 veces más barata por época.

Peor y más caro: no hay compromiso que negociar.

§ 2

Diseño experimental

Push-T: contacto intermitente y varias soluciones válidas

- Empujar una pieza en T hasta la silueta objetivo.
- Imagen cenital 96×96 y posición del efector.
- 206 demostraciones, 25650 transiciones, 90 episodios de entrenamiento.

Chi *et al.* (2025).

Pocas demostraciones: el régimen donde el preentrenamiento debería ayudar.

La política aprende a predecir el ruido, condicionada por la imagen

$$\mathcal{L} = \mathbb{E} \left[\left\| \underbrace{\epsilon^k}_{\text{ruido inyectado}} - \epsilon_{\theta}(\mathbf{O}_t, \mathbf{A}_t^0 + \epsilon^k, k) \right\|^2 \right]$$

donde $\mathbf{O}_t$ son las $T_o = 2$ observaciones y $\mathbf{A}_t^0$ la secuencia de $T_p = 16$ acciones reales.

La política aprende a predecir el ruido, condicionada por la imagen

$$\mathcal{L} = \mathbb{E} \left[\left\| \underbrace{\epsilon^k}_{\text{ruido inyectado}} - \epsilon_{\theta}(\mathbf{O}_t, \mathbf{A}_t^0 + \epsilon^k, k) \right\|^2 \right]$$

donde $\mathbf{O}_t$ son las $T_o = 2$ observaciones y $\mathbf{A}_t^0$ la secuencia de $T_p = 16$ acciones reales.

$\mathbf{O}_t$ entra como **condicionamiento**, no se genera. Lo que el codificador no ponga en ese vector de 512 componentes, el generador no lo tiene.

Cinco codificadores, un solo factor manipulado

	Codificador	Pesos iniciales	Estrategia	Entrenables (M)
V0	ResNet-18	aleatorios	desde cero	288
V1	ResNet-18	ImageNet-1k	congelado	277
V2	ResNet-18	ImageNet-1k	ajuste fino	288
V3	DINOv2 ViT-S/14	LVD-142M	congelado	277
V4	CLIP ViT-B/16	WIT-400M	congelado	277

V3 y V4 siguen en ejecución: esta charla cubre las tres variantes convolucionales.

Constantes: generador, hiperparámetros, semilla 42, partición y protocolo de evaluación.


- Cada 50 épocas, 50 episodios de bucle cerrado, semillas reservadas.
- Puntuación: cobertura máxima del objetivo, saturada en $\tau = 0,95$.
- Se guarda el punto de control de mayor puntuación media.

Esos episodios **seleccionan** el modelo: no son prueba independiente.

§ 3

Resultados

La línea base se estabiliza cerca de 0,86; las preentrenadas retroceden



Media sobre los 50 episodios reservados; barras de error estándar. Estrellas: punto de control seleccionado.


Las dos diferencias frente a la línea base excluyen el cero

	Mejor puntuación	IC 95 % de la diferencia	Wilcoxon
V0 desde cero	0,864		
V1 congelado	0,668	[0,091; 0,303]	$p = 0,0004$
V2 ajuste fino	0,648	[0,102; 0,332]	$p = 0,0001$
V1 frente a V2	0.020	[−0,093; 0,133]	$p = 0,82$

Diferencias pareadas sobre los 50 episodios comunes. V0: época 350; V1 y V2: época 150.

■ Caídas del 23 % y del 25 %. Entre congelar y ajustar, en cambio, no hay diferencia medible.

Las preentrenadas memorizan: la validación sube mientras el ajuste mejora



V1, entre las épocas 150 y 450: entrenamiento $0,0145 \rightarrow 0,00166$, validación $0,0869 \rightarrow 0,2247$.

Congelar no abarata nada si obliga a subir la imagen a 224 píxeles

	Minutos por época	Factor	Horas totales
V0 (96 px)	1,5	—	17,4
V1 (224 px)	5,3	3,5	96,5
V2 (224 px)	14,7	9,8	84,9

V2 acumula menos horas solo porque se detuvo en la época 266. Total del experimento: 198,8 h sobre una RTX 3070 Ti de 8 GB.

■ V1 entrena un 4 % menos de parámetros y aun así cuesta tres veces y media más: manda la **resolución de entrada**.

§ 4

Qué se puede afirmar

Por qué ImageNet no ayuda en un tablero sintético

- Figuras geométricas sobre fondo uniforme: ni textura ni categorías.
- La tarea la decide la posición relativa de dos formas.
- V0 guarda esa geometría con *spatial softmax*; V1 y V2 dan un descriptor global.

Coherente con R3M (Nair *et al.*, 2022) y con DINOv3 (Egbe *et al.*, 2025).

Dónde falla este estudio

- Entre V0 y V1–V2 cambian **cuatro factores a la vez**: inicialización, resolución, recorte y agregación espacial.
- Una sola semilla: los intervalos cubren episodios, no réplicas.
- Sin V3 ni V4, convolucionales frente a ViT sigue abierto.

■ Se compara el bloque codificador + preprocesado, no la inicialización aislada.

Para llevarse a casa

1. Con 206 demostraciones de Push-T, la ResNet-18 desde cero ganó por 0,197 y 0,217 puntos.
2. Ajustar los pesos preentrenados no aportó ventaja sobre congelarlos ($p = 0,82$).
3. Siguiente paso: cerrar V3 y V4; entrenar desde cero a 224 px.

Bifurcación propia de `diffusion_policy` · 1266 épocas ejecutadas

Material de apoyo para el turno de preguntas

$$\mathbf{A}_t^{k-1} = \alpha \left(\mathbf{A}_t^k - \gamma \epsilon_{\theta}(\mathbf{O}_t, \mathbf{A}_t^k, k) + \mathcal{N}(0, \sigma^2 I) \right)$$

donde α , γ y σ los fija el planificador DDPM, con 100 pasos en entrenamiento e inferencia.

- El ruido fresco de cada paso preserva los distintos modos de acción.
- Se predicen $T_p = 16$ acciones y se ejecutan las $T_a = 8$ primeras antes de replanificar.

$$s_j = \max_{1 \leq t \leq T} \min\left(\frac{c_{j,t}}{\tau}, 1\right)$$

donde $c_{j,t}$ es la fracción del área objetivo cubierta y $\tau = 0,95$.

- Se toma el máximo del episodio porque la pieza puede desplazarse después.
- Se reporta la media sobre 50 episodios, con su error estándar.

Media de las tres últimas evaluaciones

	Mejor	Media últimas 3	ECM de la acción
V0	0,864	0,862	116,17
V1	0,668	0,547	147,31
V2	0,648	0,585	42,86

V2 logra el menor error sobre acciones del conjunto de datos y aun así no gana la tarea: precisión en cadena abierta y control en bucle cerrado no miden lo mismo.

Hiperparámetros comunes


Parámetro	Valor
Horizontes $T_p/T_o/T_a$	16 / 2 / 8
Pasos de difusión	100 (DDPM, varianza fija)
Optimizador	AdamW, 1×10^{-4} , decaimiento coseno
Media móvil exponencial	activada
Tamaño de lote	64 (32 en V4)
Presupuesto	500 épocas, parada anticipada
Semilla	42

Parada anticipada: sin superar el máximo en dos evaluaciones consecutivas y nunca antes de la época 200. Solo llegó a aplicarse a V2.

Comprobación cualitativa, misma condición inicial

V1 congelado, máximo 0,9544

epoch=0150-test_mean_score=0.668.ckpt | seed=10049 | max_reward=0.954



V2 ajuste fino, máximo 0,8818

epoch=0150-test_mean_score=0.648.ckpt | seed=10049 | max_reward=0.882



Semilla 10049, fuera del intervalo oficial 100000–100049. Un solo episodio: ilustra el comportamiento, no estima el rendimiento medio.

- Completar V3 y V4: ¿el problema es ImageNet o todo preentrenamiento ajeno a la robótica?
- Desde cero a 224 px sin recorte, unas 85 h; a 96 px sin recorte, unas 17 h.
- Semillas 43 y 44 sobre las variantes seleccionadas.
- Evaluar sobre semillas disjuntas de las de selección.